

Missão Prática | Nível 3 | Mundo 5

Microatividade 1

Descrever como ler um arquivo CSV usando a biblioteca Pandas (Python)

- Salve o conjunto de dados em formato CSV que utilizará num local acessível pela ferramenta de escrita de código que utilizará;
- 2. Crie um novo arquivo e:
 - a. Importe a biblioteca pandas;
 - b. Cria uma variável;
 - c. Leia o conteúdo do arquivo CSV, passando como parâmetros o separador de colunas, a engine com o valor 'python' e o enconding relativo aos dados constantes no arquivo lido (esse último parâmetro pode ser opcional, dependendo do enconding existente);
 - d. Atribua os dados lidos do CSV à variável criada anteriormente; Salve as alterações;
 - e. Imprima/exiba em tela os dados da variável.

```
0
     import pandas as pd
     dados_exercicio = None
    dados_exercicio = pd.read_csv(
         '/content/trabalho_03.csv',
          sep=';',
         engine='python',
         encoding='utf-8'
    print(dados_exercicio)
₹
                               Date Pulse Maxpulse Calories
         ID Duration
                       '2020/12/01'
         0
                   60
                                        110
                                                  130
                                                           4091
                       '2020/12/02'
         1
                   60
                                        117
                                                  145
                                                          4790
    1
                       '2020/12/03'
                   60
                                        103
                                                  135
                                                           3400
                   45
                       '2020/12/04'
                                        109
                                                  175
                                                           2824
         4
                   45
                       '2020/12/05'
                                        117
                                                  148
                                                           4060
                   60
                       '2020/12/06'
                                        102
                                                  127
                                                           3000
                       '2020/12/07'
    6
                   60
                                        110
                                                  136
                                                           3740
                  450
                       '2020/12/08'
                                        104
                                                  134
                                                          2533
    8
                   30
                       '2020/12/09'
                                        109
                                                  133
                                                           1951
         8
                       '2020/12/10'
    9
                                        98
                                                  124
                   60
                                                           2690
                       '2020/12/11'
    10
        10
                   60
                                        103
                                                  147
                                                           3293
                       '2020/12/12'
    11
        11
                   60
                                        100
                                                  120
                                                           2507
                       '2020/12/12'
                   60
                                        100
                                                  120
                                                           2507
       13
    13
                   60
                       '2020/12/13'
                                        106
                                                  128
                                                           3453
    14
       14
                   60 '2020/12/14'
                                        104
                                                  132
                                                           3793
                       '2020/12/15'
                                        98
    15
       15
                   60
                                                  123
                                                           2750
                       '2020/12/16'
                                         98
    16
        16
                   60
                                                  120
                                                           2152
                       '2020/12/17'
    17
        17
                   60
                                        100
                                                  120
                                                           3000
                        '2020/12/18'
    18
        18
                   45
                                         90
                                                  112
                                                           NaN
    19
        19
                   60
                       '2020/12/19'
                                        103
                                                  123
                                                           3230
    20
       20
                   45
                       '2020/12/20'
                                                  125
                                                         2430 2
    21
        1
                   60
                       '2020/12/21'
                                        108
                                                  131
                                                           3642
    22 22
                   45
                                NaN
                                        100
                                                  119
                                                           2820
    23 23
                   60
                       '2020/12/23'
                                        130
                                                  101
                                                           3000
                       '2020/12/24'
    24
        24
                   45
                                        105
                                                  132
                                                           2460
                       '2020/12/25'
    25
        25
                   60
                                        102
                                                  126
                                                           3345
       26
    26
                   60
                           20201226
                                        100
                                                  120
                                                           2500
                       '2020/12/27'
    27 27
                                        92
                                                  118
                   60
                                                           2410
    28
       28
                   60
                       '2020/12/28'
                                        103
                                                  132
                                                           NaN
    29
        29
                   60
                       '2020/12/29'
                                        100
                                                  132
                                                           2800
    30
       30
                   60
                       '2020/12/30'
                                        102
                                                  129
                                                           3803
                       '2020/12/31'
                                                  115
                                                           2430
                   60
```

Descrever como criar um subconjunto de dados a partir de um conjunto existente usando a biblioteca Pandas (Python)

- 1. No mesmo arquivo/script utilizado na microatividade 1, crie uma nova variável;
- 2. Atribua, a essa nova variável, um subconjunto de dados contendo apenas parte das colunas (recomenda-se a utilização de 3 colunas) disponíveis no conjunto de dados original;
- 3. Salve as alterações realizadas;
- 4. Imprima/exiba em tela os dados da nova variável (que contém o subconjunto de dados).

```
subconjunto_dados = dados_exercicio[['Date', 'Pulse', 'Calories']]
     print(subconjunto dados)
Date Pulse Calories
0 '2020/12/01' 110 4091
1 '2020/12/02' 117 4790
2 '2020/12/03' 103 3400
3 '2020/12/04' 109 2824
4 '2020/12/05' 117 4060
5 '2020/12/06' 102 3000
6 '2020/12/07' 110 3740
7 '2020/12/08' 104 2533
8 '2020/12/09' 109 1951
9 '2020/12/10' 98 2690
10 '2020/12/10' 98 2690
10 '2020/12/11' 103 3293
11 '2020/12/11' 103 3293
11 '2020/12/12' 100 2507
12 '2020/12/12' 100 2507
13 '2020/12/13' 106 3453
14 '2020/12/14' 104 3793
15 '2020/12/14' 104 3793
15 '2020/12/16' 98 2152
17 '2020/12/16' 98 2152
17 '2020/12/16' 98 2152
17 '2020/12/17' 100 3000
18 '2020/12/18' 90 NaN
19 '2020/12/18' 90 NaN
19 '2020/12/19' 103 3230
20 '2020/12/20' 97 2430 2
21 '2020/12/21' 108 3642
22 NaN 100 2820
                                                        Date Pulse Calories
  21 '2020/12/21' 108
22 NaN 100
23 '2020/12/23' 130
24 '2020/12/24' 105
25 '2020/12/25' 102
26 20201226 100
27 '2020/12/27' 92
28 '2020/12/28' 103
29 '2020/12/29' 100
30 '2020/12/30' 102
31 '2020/12/31' 92
                                                                                                                         2820
                                                                                                                              3000
                                                                                                                              2460
                                                                                                                        3345
                                                                                                                        2500
                                                                                                                         2410
                                                                                                                             NaN
                                                                                                                              2800
                                                                                                                         3803
     31 '2020/12/31'
                                                                                           92
                                                                                                                              2430
```

Descrever como configurar o número máximo de linhas a serem exibidas na visualização de um conjunto de dados usando a biblioteca Pandas (Python)

- 1. Abra o arquivo/script utilizado nas microatividades anteriores;
- Usando as opções de configuração da biblioteca pandas, defina um novo valor para a propriedade "max_rows", definindo o novo valor para 9999;
- 3. Salve as alterações;
- 4. Imprima na tela o conjunto de dados original (criado na microatividade 1) usando o método "to_string()".

			481.		000			1
ls O	pa.	орті	.ons.aispia	y.max_rows = 9	1999			
	dad	los e	vercicio =	nd read csv('	trahalh	n 03 csv'	sen='''	engine='python', encoding='utf-8')
	uuu	.03_0	ACI CICIO -	pa.r.caa_csv(CI abali	.o_oɔ.cɔv ,	3cp- , ,	engine python , theoding att o)
	pri	nt(d	lados exerc	icio.to_string	(())			
		ID	Duration	Date	Pulse	Maxpulse	Calories	
	0	0	60	'2020/12/01'	110	130	4091	
	1	1	60	'2020/12/02'	117	145	4790	
	2	2	60	'2020/12/03'	103	135	3400	
	3	3	45	'2020/12/04'	109	175	2824	
	4	4	45	'2020/12/05'	117	148	4060	
	5	5	60	'2020/12/06'	102	127	3000	
	6	6	60	'2020/12/07'	110	136	3740	
	7	7	450	'2020/12/08'	104	134	2533	
	8	8	30	'2020/12/09'	109	133	1951	
	9	9	60	'2020/12/10'	98	124	2690	
	10	10	60	'2020/12/11'	103	147	3293	
	11	11	60	'2020/12/12'	100	120	2507	
	12	12	60	'2020/12/12'	100	120	2507	
	13	13	60	'2020/12/13'	106	128	3453	
	14	14	60	'2020/12/14'	104	132	3793	
	15	15	60	'2020/12/15'	98	123	2750	
	16	16	60	'2020/12/16'	98	120	2152	
	17	17	60	'2020/12/17'	100	120	3000	
	18	18	45	'2020/12/18'	90	112	NaN	
	19	19	60	'2020/12/19'	103	123	3230	
	20	20	45	'2020/12/20'	97	125	2430 2	
	21	1	60	'2020/12/21'	108	131	3642	
	22	22	45	NaN	100	119	2820	
	23	23	60	'2020/12/23'	130	101	3000	
	24	24	45	'2020/12/24'	105	132	2460	
	25	25	60	'2020/12/25'	102	126	3345	
	26	26	60	20201226	100	120	2500	
	27	27	60	'2020/12/27'	92	118	2410	
	28	28	60	'2020/12/28'	103	132	NaN	
	29	29	60	'2020/12/29'	100	132	2800	
	30	30	60	'2020/12/30'	102	129	3803	
	31	31	60	'2020/12/31'	92	115	2430	

Descrever como exibir as primeiras e últimas "N" linhas de um conjunto de dados usando a biblioteca Pandas (Python)

- 1. Abra o arquivo/script utilizado nas microatividades anteriores;
- 2. Imprima na tela as apenas as primeiras 10 linhas do conjunto de dados original (criado na microatividade 1);
- 3. Imprima na tela as apenas as últimas 10 linhas do conjunto de dados original (criado na microatividade 1).

```
pd.options.display.max rows = 20
     dados_exercicio = pd.read_csv('trabalho_03.csv', sep=';', engine='python', encoding='utf-8')
     print("Primeiras 10 linhas:")
     print(dados_exercicio.head(10))
     print("\nÚltimas 10 linhas:")
      print(dados_exercicio.tail(10))

→ Primeiras 10 linhas:
    ID Duration
                                    Date Pulse Maxpulse Calories
     Últimas 10 linhas:
         ID Duration
                             Date Pulse maxpulse
NaN 100 119
                                    Date Pulse Maxpulse Calories
     22 22 45 NaN 100
23 23 60 '2020/12/23' 130
24 24 45 '2020/12/24' 105
25 25 60 '2020/12/25' 102
26 26 60 2020/12/27' 92
27 60 '2020/12/27' 92
28 28 60 '2020/12/28' 103
                                                                      2820
                              101

2020/12/25' 102 126

20201226 100 120

2020/12/27' 92 118

2020/12/28' 103 132

1020/12/29' 100 132

020/12/30' 102 129

020/12/31' 92 115
                                                            101
                                                                        3000
                                                                       2460
                                                                       3345
                                                                        2500
                                                                        2410
                  60 '2020/12/28'
60 '2020/12/29'
60 '2020/12/30'
                                                                         NaN
     29 29
30 30
31 31
                                                                        2800
                                                                        3803
                      60 '2020/12/31'
                                                                        2430
```

Descrever como exibir informações gerais sobre as colunas, linhas e dados de um conjunto de dados usando a biblioteca Pandas (Python)

- 1. Abra o arquivo/script utilizado nas microatividades anteriores;
- 2. Tendo como base o conjunto de dados original:
- A. Imprima as informações gerais sobre o conjunto suas colunas, linhas e dados:
- B. Descubra a partir do comando acima:
- I. O total de linhas;
- II. O total de colunas;
- III. A quantidade de dados nulos, caso existam;
- IV. O tipo de dado de cada coluna;
- V. A quantidade de memória utilizada pelo conjunto de dados.

Missão Prática | Tratando a imensidão dos dados

- 1. Para essa atividade você deverá, obrigatoriamente, utilizar o conjunto de dados (fornecido anteriormente, na seção "Contextualização") composto pelas colunas ID;Duration;Date;Pulse;Maxpulse;Calories
- Crie um novo arquivo/script;
- 3. Leia o conteúdo do CSV fornecido, atentando-se para a necessidade ou não de incluir parâmetros adicionais como os relativos ao separador dos dados, a engine e o enconding;
- 4. Atribua os dados lidos a uma variável;
- 5. Verifique se os dados foram importados adequadamente:
 - i. Imprima as informações gerais sobre o conjunto de dados;
 - ii. Imprima as primeiras e últimas N linhas do arquivo.
- 6. Crie uma nova variável e atribua a ela uma cópia do conjunto de dados original (variável criada no passo 4);
- 7. Nessa nova variável, contendo uma cópia dos dados:
 - i. Substitua todos os valores nulos da coluna 'Calories' por 0;
 - ii. Imprima o conjunto de dados para verificar se a mudança acima foi aplicada com sucesso;
- 8. Ainda na nova variável:
 - i. Substitua os valores nulos da coluna 'Date' por '1900/01/01';
 - ii. Imprima o conjunto de dados e confira se a mudança foi aplicada com sucesso;
 - iii. Transforme os dados da coluna 'Date' em datetime usando o método 'to_datetime';

- 9. Tendo seguido todas as instruções anteriores, ao executar o passo anterior você deverá ter encontrado um erro informando que o valor '1900/01/01' não corresponde ao formato '%Y/%m/%d'. Para resolver esse problema:
 - i. Substitua, na coluna 'Date', o valor '1900/01/01' por 'NaN';
 - ii. Utilizando o método 'to_datetime', repita o passo de transformação dos dados da coluna 'Date' para datetime;
 - iii. Imprima o conjunto de dados para verificar se as mudanças acima foram aplicadas com sucesso;
- 10. Nesse ponto, você deverá ter esbarrado em outro erro, informando agora que o valor "20201226" não corresponde ao formato ""%Y/%m/%d" . Você precisará, agora, na coluna 'Date", transformar especificamente esse valor, atualmente uma string, para o formato datetime. Para isso você deverá combinar os métodos 'replace' e 'to datetime';
- 11. Após o passo anterior, execute novamente a transformação de todos os dados da coluna 'Date' para o formato datetime (usando o to_datetime). Imprima o conjunto de dados atual para verificar se todas as transformações foram executadas com sucesso;
- 12. Por fim, remova os registros contendo valores nulos. Nesse ponto, apenas a coluna 'Date' possui um registro que atende a essa premissa (linha 22). Logo, utilize-a como base para realizar a transformação solicitada;
- 13. Imprima o dataframe e verifique se todas as transformações foram executadas conforme solicitado nos passos anteriores.

```
[ ] import pandas as pd
    import numpy as np
dados_exercicio = pd.read_csv('trabalho_03.csv', sep=';', engine='python', encoding='utf-8')
    print("Informações gerais sobre o conjunto de dados:")
    dados_exercicio.info()
    print("\nPrimeiras 5 linhas:")
    print(dados_exercicio.head(5))
    print("\nÚltimas 5 linhas:")
    print(dados_exercicio.tail(5))
    dados_exercicio_copia = dados_exercicio.copy()
    dados_exercicio_copia['Calories'].fillna(0, inplace=True)
    print("\nDados após substituir valores nulos em 'Calories' por 0:")
    print(dados_exercicio_copia)
    dados_exercicio_copia['Date'].fillna('1900/01/01', inplace=True)
    print("\nDados após substituir valores nulos em 'Date' por '1900/01/01':")
    print(dados_exercicio_copia)
    dados_exercicio_copia['Date'] = dados_exercicio_copia['Date'].str.replace("'", "")
        dados_exercicio_copia['Date'] = pd.to_datetime(dados_exercicio_copia['Date'], format='%Y/%m/%d', errors='coerce')
    except Exception as e:
        print("\nErro ao converter a coluna 'Date' para datetime:", e)
    dados_exercicio_copia['Date'].replace('1900/01/01', np.nan, inplace=True)
    dados_exercicio_copia['Date'] = pd.to_datetime(dados_exercicio_copia['Date'], errors='coerce')
    print("\nDados após substituir '1900/01/01' por NaN e converter para datetime:")
    print(dados_exercicio_copia)
    dados_exercicio_copia['Date'] = dados_exercicio_copia['Date'].replace('20201226', '2020/12/26')
    dados_exercicio_copia['Date'] = pd.to_datetime(dados_exercicio_copia['Date'], errors='coerce')
    print("\nDados após corrigir o valor '20201226' e converter para datetime:")
    print(dados_exercicio_copia)
    dados_exercicio_copia.dropna(subset=['Date'], inplace=True)
    print("\nDataFrame final após todas as transformações:")
    print(dados_exercicio_copia)
```

```
Informações gerais sobre o conjunto de dados:
    <class 'pandas.core.frame.DataFrame'>
RangeIndex: 32 entries, 0 to 31
    Data columns (total 6 columns):
    # Column Non-Null Count Dtype
--- ---- 0 ID 32 non-null int64
        Duration 32 non-null
                                    int64
        Date
                   31 non-null
                                    obiect
        Pulse
                   32 non-null
     4 Maxpulse 32 non-null
5 Calories 30 non-null
                                    int64
                                    object
    dtypes: int64(4), object(2)
    memory usage: 1.6+ KB
    Primeiras 5 linhas:
      ID Duration
                             Date Pulse Maxpulse Calories
             60 '2020/12/01'
                 60 '2020/12/02'
60 '2020/12/03'
                                                         4790
                                                         3400
                                      103
                 45 '2020/12/04'
45 '2020/12/05'
                                                         2824
                                      109
                                                         4060
    últimas 5 linhas:
        ID Duration
                              Date Pulse Maxpulse Calories
               60 '2020/12/27'
                  60 '2020/12/28'
60 '2020/12/29'
                                                          NaN
                                       103
                                       100
                                                          2800
                 60 '2020/12/30'
                                                          3803
                 60 '2020/12/31'
    31 31
    Dados após substituir valores nulos em 'Calories' por 0:
       ID Duration Date Pulse Maxpulse Calories
               60 '2020/12/01'
                                      110
        0
                  60 '2020/12/02'
60 '2020/12/03'
                                                          4790
                                                          3400
                  45 '2020/12/04'
45 '2020/12/05'
                                       109
                                                          2824
                                                 148
                                                         4060
                  60 '2020/12/27'
                                                          2410
                  60 '2020/12/28'
    28 28
                  60 '2020/12/29'
    29 29
                                       100
                                                          2800
                  60 '2020/12/30'
                                                          3803
                 60 '2020/12/31'
    31 31
                                                          2430
    [32 rows x 6 columns]
```

```
Dados após substituir valores nulos em 'Date' por '1900/01/01':
    ID Duration
                        Date Pulse Maxpulse Calories
            60 '2020/12/01'
    0
                              110
                                        130
            60 '2020/12/02'
60 '2020/12/03'
45 '2020/12/04'
                                                4790
                                        145
                               103
                                        135
                                                3400
                               109
                                        175
                                                2824
            45 '2020/12/05'
                               117
                                        148
                                                4060
                              92
                                       118
            60 '2020/12/27'
                                                2410
27
            60 '2020/12/28'
28 28
                             103
                                                0
            60 '2020/12/29'
29 29
                               100
                                       132
                                                2800
30 30
            60 '2020/12/30'
                                       129
                             102
                                               3803
            60 '2020/12/31'
31 31
                              92
                                       115
                                               2430
[32 rows x 6 columns]
Dados após substituir '1900/01/01' por NaN e converter para datetime:
   ID Duration Date Pulse Maxpulse Calories
           60 2020-12-01 110
                                    130
                                             4091
            60 2020-12-02
                            117
                                     145
                                             4790
            60 2020-12-03
                            103
                                    135
                                             3400
            45 2020-12-04
                            109
                                    175
                                             2824
4 4
            45 2020-12-05
                                    148
                                             4060
27 27
            60 2020-12-27
                                    118
                                             2410
            60 2020-12-28
                          103
                                    132
                                              0
            60 2020-12-29
                            100
                                    132
                                             2800
            60 2020-12-30
                            102
                                             3803
            60 2020-12-31
                                    115
                                             2430
[32 rows x 6 columns]
Dados após corrigir o valor '20201226' e converter para datetime:
   ID Duration Date Pulse Maxpulse Calories
    0
           60 2020-12-01
                           110
                                   130
                                             4091
0
            60 2020-12-02
                            117
                                      145
                                             4790
             60 2020-12-03
                            103
                                      135
                                             3400
            45 2020-12-04
                            109
                                      175
                                             2824
            45 2020-12-05
                            117
                                      148
                                             4060
            60 2020-12-27
                                      118
                                             2410
   28
            60 2020-12-28
                            103
29 29
             60 2020-12-29
                            100
                                      132
                                             2800
30 30
             60 2020-12-30
                            102
                                      129
                                             3803
31 31
            60 2020-12-31
                                      115
                                             2430
```

[32 rows x 6 columns]

			após todas a				
	ID	Duration	Date	Pulse	Maxpulse	Calories	
0	0	60	2020-12-01	110	130	4091	
1	1	60	2020-12-02	117	145	4790	
2	2	60	2020-12-03	103	135	3400	
3	3	45	2020-12-04	109	175	2824	
4	4	45	2020-12-05	117	148	4060	
27	27	60	2020-12-27	92	118	2410	
28	28	60	2020-12-28	103	132	0	
29	29	60	2020-12-29	100	132	2800	
30	30	60	2020-12-30	102	129	3803	
31	31	60	2020-12-31	92	115	2430	